

# Informe de Librerías Utilizadas

Proyecto GDDL — Geometry Dash Demon List Analysis

## 1. Introducción

Este informe describe las librerías de Python empleadas en el proyecto de análisis estadístico del dataset de Geometry Dash Demon List (GDDL). El proyecto tiene como objetivo estudiar la relación entre la dificultad de los niveles (Tier), el disfrute de los usuarios (Enjoyment) y otros metadatos como la canción empleada o el creador del nivel. A continuación se detallan las cuatro librerías principales utilizadas, junto con sus funciones más relevantes y ejemplos de uso en el contexto del proyecto.

## 2. pandas

### 2.1 Descripción

pandas es la librería estándar de Python para manipulación y análisis de datos tabulares. Proporciona la estructura de datos **DataFrame**, que permite operar sobre tablas de forma eficiente, similar a una hoja de cálculo o una tabla SQL, pero con toda la potencia de Python. Es la base de todo el proyecto: la carga del dataset, el filtrado de registros y los cálculos estadísticos se realizan sobre objetos DataFrame de pandas.

### 2.2 Funciones más relevantes empleadas

| Función / Método             | Descripción                                                 |
|------------------------------|-------------------------------------------------------------|
| pd.read_csv()                | Carga el dataset GDDL desde un archivo CSV en un DataFrame. |
| df.columns.str.strip()       | Elimina espacios en los nombres de columnas tras la carga.  |
| df[condición]                | Filtra filas del DataFrame según una condición booleana.    |
| df.sort_values(by=col)       | Ordena el DataFrame por una columna dada.                   |
| df.groupby(col)[col2].mean() | Agrupar y calcular la media de una columna por grupos.      |
| df[col].value_counts()       | Cuenta la frecuencia de cada valor en una columna.          |
| df.loc[idx, col]             | Accede a un valor por etiqueta de índice y columna.         |
| df.iloc[pos]                 | Accede a una fila por posición entera.                      |
| Series.corr()                | Calcula la correlación de Pearson entre dos Series.         |

Series.idxmax() / idxmin()

Devuelve el índice del valor máximo o mínimo.

## 2.3 Ejemplo de uso en el proyecto

El siguiente fragmento muestra cómo se carga el dataset y se aplica un filtro para obtener niveles con Enjoyment mayor que 7 usando la canción indicada:

```
df = pd.read_csv('gddl_dataset.csv') df.columns = df.columns.str.strip() # Filtrar niveles expertos con una canción específica resultado = df[(df['Enjoyment'] > 7) & (df['Song'] == 'Theory of everything 2')]
```

## 3. NumPy

### 3.1 Descripción

NumPy (Numerical Python) es la librería fundamental para computación numérica en Python. Proporciona el tipo ndarray para operaciones vectorizadas de alto rendimiento y una amplia colección de funciones matemáticas. En este proyecto se utiliza directamente para calcular métricas estadísticas descriptivas sobre las puntuaciones de disfrute del dataset.

### 3.2 Funciones más relevantes empleadas

| Función                 | Descripción                                                |
|-------------------------|------------------------------------------------------------|
| np.mean(array)          | Calcula la media aritmética de los valores de disfrute.    |
| np.std(array)           | Calcula la desviación estándar del disfrute en el dataset. |
| np.median(array)        | Calcula la mediana; útil para distribuciones asimétricas.  |
| np.percentile(array, q) | Obtiene el percentil q de una distribución.                |

### 3.3 Ejemplo de uso en el proyecto

En la función estadisticas\_globales() se usa NumPy para calcular la media y la desviación estándar del disfrute de todos los niveles del dataset:

```
import numpy as np def estadisticas_globales(df): return { 'media': np.mean(df['Enjoyment']), 'desviacion': np.std(df['Enjoyment']) }
```

## 4. Matplotlib y Seaborn

### 4.1 Descripción

Matplotlib es la librería de visualización de referencia en Python, que permite crear gráficas estáticas, animadas e interactivas. Seaborn es una capa de alto nivel construida sobre Matplotlib que facilita la creación de gráficas estadísticas atractivas con menos código. Juntas, se usan en el proyecto para generar las cuatro visualizaciones principales del análisis del dataset GDDL.

### 4.2 Funciones más relevantes empleadas

| Función            | Librería   | Descripción                                                         |
|--------------------|------------|---------------------------------------------------------------------|
| sns.histplot()     | Seaborn    | Histograma con curva KDE para ver distribuciones (Tier, Enjoyment). |
| sns.scatterplot()  | Seaborn    | Nube de puntos para visualizar la relación Tier vs Enjoyment.       |
| sns.regplot()      | Seaborn    | Añade la línea de regresión sobre el scatter plot.                  |
| sns.lineplot()     | Seaborn    | Línea temporal del disfrute medio por nivel de dificultad.          |
| plt.fill_between() | Matplotlib | Área sombreada bajo la curva de disfrute medio.                     |
| plt.savefig()      | Matplotlib | Exporta las gráficas a archivo PNG en alta resolución.              |
| sns.set_theme()    | Seaborn    | Aplica un tema visual uniforme a todas las gráficas.                |

### 4.3 Ejemplo de uso en el proyecto

El siguiente código genera el gráfico de dispersión entre la dificultad y el disfrute, incluyendo la línea de regresión lineal:

```
import matplotlib.pyplot as plt
import seaborn as sns
sns.set_theme(style='whitegrid')
plt.figure(figsize=(12, 6))
sns.scatterplot(data=df, x='Tier', y='Enjoyment', alpha=0.3, color='#3498db', s=20)
sns.regplot(data=df, x='Tier', y='Enjoyment', scatter=False, color='red', line_kws={'linewidth': 2})
plt.title('Relacion: Dificultad vs Disfrute', fontsize=14)
plt.savefig('scatter.png', dpi=300)
plt.close()
```

## 5. Resumen y conclusión

Las tres librerías descritas forman un ecosistema coherente y complementario para el análisis de datos en Python. pandas actúa como núcleo de la manipulación de datos, NumPy aporta las operaciones matemáticas de bajo nivel, y Matplotlib junto con Seaborn se encargan de las visualizaciones estáticas de alta calidad para comunicar los resultados.

| Librería | Versión típica | Rol en el proyecto                                     |
|----------|----------------|--------------------------------------------------------|
| pandas   | 2.x            | Carga, filtrado, agrupación y manipulación del dataset |
| NumPy    | 1.26.x         | Cálculo de media y desviación estándar del disfrute    |

|            |        |                                                             |
|------------|--------|-------------------------------------------------------------|
| Matplotlib | 3.8.x  | Base de renderizado para todas las gráficas estáticas       |
| Seaborn    | 0.13.x | Visualizaciones estadísticas de alto nivel sobre Matplotlib |